电影评论情感分类

电影评论情感分类

- 1 实验概述
- 2 实验环境
 - 2.1 硬件环境
 - 2.2 软件环境
 - 2.3 Conda环境
- 3 实验思路
 - 3.1 数据来源
 - 3.2 数据预处理
 - 3.3 模型选择与参数设置
- 4 实验代码
 - 4.1 数据载入部分
 - 4.2 模型部分
 - 4.3 训练部分
 - 4.4 测试部分
- 5 实验结果
 - 5.1 训练部分输出展示
 - 5.2 Train Loss图像
 - 5.3 Validation ACC图像
 - 5.4 测试集ACC
- 6总结

1 实验概述

本实验目的是设计一个模型来对电影评论进行二元情感分类,判断该评论的内容是积极还是消极。

2 实验环境

• 2.1 硬件环境

• CPU: Intel i5-12500H

• GPU: NVIDIA Geforce RTX 2050 (4GB)

• 2.2 软件环境

- Windows 11
- Anaconda

• 2.3 Conda环境

- python=3.9
- pytorch=2.0.0
- pytorch-cuda=11.8
- gensim=4.3.1

3 实验思路

• 3.1 数据来源

本次实验的数据来自实验提供,包含4个文件:

• train.txt: 训练集

• validation.txt:验证集

• test.txt: 测试集

• wiki_word2vec_50.bin: 词向量

• 3.2 数据预处理

原始样本集内容如图所示:

```
1 看 完 这个 电影 我 想 说 我 今年 看过 最烂 电影 没有 情节 没有 内容 没有 主旨 不 知道 为什么 还有 这个 分数 可能 为了 效果 这种 之 豆瓣 看不懂 电影 又 装 无比 文艺 傻 青年 太多 电影 确实 不怎么样 笑料 无力 卖弄 理想 情节 拖沓 套路 化 实在 看不下去 不过 倒 确实 1 我 今年 看过 最差 一部 电影 主线 不 清晰 基本上 没有 剧情 可言 无限 坑 爹 特别 妹妹 不 知道 他 里面 干什么 你 敢 说 他 不 爱 沈秋 1 说 中国 难得 赚钱 几部 动画片 之一 又 强大 配音 阵容 特意 下载 下来 看 看得 我 郁闷 不行 无聊 两字 怎能 充分 表达 我 心情 好 我 方 白花钱 去 电影院 看 除了 对比 强烈 色彩 其他 我 找不出 什么 好 地方 噢 对 剧情 毕竟 改编 科恩 兄弟 忽然 才 发现 张艺谋 电影 这个 一腔 情怀 也 流水账 里 代入 无能 做作 以为 有趣 男主 除了 长得 真帅 说话 做事 完全 讨厌 费解 这是 台剧 看到 群众 共鸣 最多 帖 说
```

其中,第一个数字表示label, 1是negative, 0是positive。后续是文本内容,已经被分词过。

因此, 所需要进行的预处理步骤为:

1. 统计样本集中所用到的词汇,整理出一个词汇索引表。

对应函数实现:

2. 使用 wiki_word2vec_50.bin 文件来将词汇转化为向量。

对应函数实现:

```
def build_word2vec(filename, word2id, save_to_path=None):
    n_words = max(word2id.values()) + 1

model = gensim.models.KeyedVectors.load_word2vec_format(filename, binary=True)

word_vecs = np.array(np.random.uniform(-1., 1., [n_words, model.vector_size]))

for word in word2id.keys():
    try:
    word_vecs[word2id[word]] = model[word]
    except KeyError:
    pass

if save_to_path:
    with open(save_to_path, 'w', encoding='utf-8') as f:
    for vec in word_vecs:
    vec = [str(w) for w in vec]
```

```
f.write(' '.join(vec))
                f.write('\n')
    return word_vecs
def cat_to_id(classes=None):
        classes = ['0', '1']
    cat2id = {cat: idx for (idx, cat) in enumerate(classes)}
def load_corpus(path, word2id, max_sen_len=50):
    _, cat2id = cat_to_id()
    contents, labels = [], []
    with open(path, encoding='utf-8') as f:
        for line in f.readlines():
            sp = line.strip().split()
                continue
            label = sp[0]
            content = [word2id.get(w, 0) for w in sp[1:]]
            content = content[:max_sen_len]
            if len(content) < max_sen_len:</pre>
                content += [word2id['_PAD_']] * (max_sen_len -
len(content))
            labels.append(label)
            contents.append(content)
    counter = Counter(labels)
    print('\tSamples num: %d' % (len(labels)))
    for w in counter:
        print('\tLabel= {}: {}'.format(w, counter[w]))
    contents = np.asarray(contents)
    labels = np.array([cat2id[l] for l in labels])
```

• 3.3 模型选择与参数设置

模型网络选择 TextCNN

参数设置如下:

```
1 # 设置超参数
2 LR = 0.001 # 学习率
3 BATCH_SIZE = 32 # 训练批量
4 EPOCH_NUM = 9 # 训练轮数
5 NUM_WORKERS = 2
6 device = torch.device('cuda:0' if torch.cuda.is_available() else 'cpu')
7
8 # 设置模型参数
```

```
9 class CONFIG:
10 update_w2v = True  # 是否在训练中更新w2v
11 vocab_size = word2vec.shape[0]  # 词汇量, 与word2id中的词汇量一致
12 n_class = 2  # 分类数: 分别为pos和neg
13 embedding_dim = word2vec.shape[1]  # 词向量维度
14 drop_prob = 0.5  # dropout层, 参数keep的比例
15 num_filters = 128  # 卷积层filter的数量
16 kernel_size = 5  # 卷积核的尺寸
17 pretrained_embed = word2vec  # 预训练的词嵌入模型
```

4 实验代码

• 4.1 数据载入部分

```
# 加载训练集与验证集
print('Loading Train Dataset ... ')
train_contents, train_labels = load_corpus('./data/train.txt', word2id, max_sen_len=50)
print('Loading Valid Dataset ... ')
val_contents, val_labels = load_corpus('./data/validation.txt', word2id, max_sen_len=50)

train_dataset =
TensorDataset(torch.from_numpy(train_contents).type(torch.float),

torch.from_numpy(train_labels).type(torch.long))
valid_dataset =
TensorDataset(torch.from_numpy(val_contents).type(torch.float),
torch.from_numpy(val_labels).type(torch.long))

train_dataloader = DataLoader(dataset = train_dataset, batch_size =
BATCH_SIZE,

shuffle = True, num_workers = NUM_WORKERS)

valid_dataloader = DataLoader(dataset = valid_dataset, batch_size =
BATCH_SIZE,

shuffle = True, num_workers = NUM_WORKERS)
```

• 4.2 模型部分

```
class TextCNN(nn.Module):
def __init__(self, config):
super(TextCNN, self).__init__()
update_w2v = config.update_w2v
vocab_size = config.vocab_size
n_class = config.n_class
embedding_dim = config.embedding_dim
num_filters = config.num_filters
```

```
drop_prob = config.drop_prob
        pretrained_embed = config.pretrained_embed
        self.embedding = nn.Embedding(vocab_size, embedding_dim)
        self.embedding.weight.data.copy_(torch.from_numpy(pretrained_embed))
        self.embedding.weight.requires_grad = update_w2v
        self.conv = nn.Conv2d(1,num_filters,(kernel_size,embedding_dim))
        self.dropout = nn.Dropout(drop_prob)
        self.fc = nn.Linear(num_filters, n_class)
    def forward(self, x):
       x = x.to(torch.int64)
       x = self.embedding(x)
        x = x.unsqueeze(1)
        x = F.relu(self.conv(x)).squeeze(3)
        x = F.max_pool1d(x, x.size(2)).squeeze(2)
        x = self.dropout(x)
       x = self.fc(x)
        return x
config = CONFIG()
model = TextCNN(config)
model.to(device)
optimizer = torch.optim.Adam(model.parameters(), lr = LR)
criterion = nn.CrossEntropyLoss()
scheduler = optim.lr_scheduler.StepLR(optimizer, step_size=3, gamma=0.5)
```

• 4.3 训练部分

```
1  # train
2  from tqdm import tqdm
3
4  train_losses = []
5  train_counter = []
6  test_accuracy = [0.0]
7  test_counter = [i*len(train_dataloader.dataset) for i in range(EPOCH_NUM + 1)]
8
9  for epoch in range(0, EPOCH_NUM):
10  model.train()
11  sum_loss = 0.0
12  correct = 0.0
13  total = 0.0
```

```
loop = tqdm(train_dataloader, total = len(train_dataloader))
    for i, data in enumerate(loop):
       length = len(train_dataloader)
        inputs, labels = inputs.to(device), labels.to(device)
       optimizer.zero_grad()
       outputs = model(inputs)
       loss.backward()
       optimizer.step()
       sum_loss += loss.item()
        total += labels.size(0)
       correct += predicted.eq(labels.data).cpu().sum()
       train_losses.append(sum_loss / (i + 1))
       if len(train_counter) = 0:
            train_counter.append(len(data))
       else:
            train_counter.append(train_counter[-1] + len(data))
        loop.set_description(f'Epoch [{epoch + 1}/{EPOCH_NUM}]')
        loop.set_postfix(loss = loss.item())
    scheduler.step()
    print('[epoch:%d] <Train> Loss: %.03f, Acc: %.3f%% ' % (epoch + 1,
train_losses[-1], 100. * correct / total), end='\t')
    with torch.no_grad():
           model.eval()
           vec, labels = vec.to(device), labels.to(device)
            outputs = model(vec)
           total += labels.size(0)
            correct += (predicted = labels).sum()
       print('<Valid> Acc: %.3f%%' % (100 * correct / total))
       test_accuracy.append(correct.item() / total)
torch.save(model.state_dict(), './' + str(EPOCH_NUM) +'epoch-model.pth')
```

```
63 torch.save(optimizer.state_dict(), './' + str(EPOCH_NUM) +'epoch-
optimizer.pth')
64 print('\nTrain has finished, total epoch is %d, model saved.' % EPOCH_NUM)
```


• 4.4 测试部分

```
print('Loading Test Dataset ...')
test_contents, test_labels = load_corpus('./data/test.txt', word2id,
TensorDataset(torch.from_numpy(test_contents).type(torch.float),
                              torch.from_numpy(test_labels).type(torch.long))
                              shuffle = True, num_workers = NUM_WORKERS)
config = CONFIG()
model_path = './9epoch-model.pth'
model = TextCNN(config)
model.load_state_dict(torch.load(model_path))
model.to(device)
with torch.no_grad():
        for data in tqdm(test_dataloader):
            model.eval()
            vec, labels = vec.to(device), labels.to(device)
            outputs = model(vec)
            total += labels.size(0)
            correct += (predicted = labels).sum()
        print('<Test> Acc: %.3f%%' % (100 * correct / total))
        test_accuracy.append(correct.item() / total)
```


5 实验结果

• 5.1 训练部分输出展示

• 5.2 Train Loss图像



• 5.3 Validation ACC图像



• 5.4 测试集ACC

100%| 12/12 [00:02<00:00, 5.24it/s]

<Test> Acc: 83.740%

6总结

从训练结果来看,模型效果并不理想。该结果在训练过程中对验证集的效果就可以猜测到。模型在训练过程中,从欠拟合到过拟合,对验证集的正确率均在80%附近。

正常来讲不应该会出现这种情况,个人猜测原因为验证集+测试集的分布与训练集有较大差距,其中存在部分训练集中没有的样本,模型在训练时根本没见过类似的分布,从而造成当前对测试集和验证集正确率都只有83%的结果。

此外通过本实验,对文本类模型的使用了解了更多,对词向量的使用也学习了不少,对整个模型的训练与测试过程更加娴熟了。